

ROTEIRO DE AULA PRÁTICA

Engenharia de Requisitos para ML com GR4ML

Caderno de Exercícios do Grupo
Preencha os templates de cada fase durante a aula

Centro de Informática — CIn/UFPE
Especialização em Deep Learning · Disciplina: Engenharia de Software para IA

Grupo (nome dos integrantes)	Projeto da disciplina
César Augusto de Carvalho Calafrioli Mões	
Anthony Silva Ferreira	
Gustavo Camara Bastos	
Jhonata Lima de Souza	
Paulo Brandão	
George Queiroz	
Pedro Roncoli Sarmet Moreira	
Bruno Oliveira	

Como usar este caderno

Este material acompanha o roteiro de aula prática de Engenharia de Requisitos com o framework GR4ML (Goal-Oriented Requirements Engineering for Machine Learning). Cada fase da aula está organizada da mesma forma, para facilitar o acompanhamento:

-  **Ideia central** — uma explicação simples do que a fase/ passo quer resolver, sem jargão técnico.
-  **Exemplo** — um exemplo já resolvido, usando o caso de uma plataforma de streaming que quer reduzir cancelamento de assinaturas (nosso 'fio condutor' do início ao fim).
-  **Entregável** — a frase que diz exatamente o que vocês precisam ter em mãos ao final daquele passo.
-  **Espaço para preencher** — um template em branco para o grupo completar com o próprio projeto, durante a aula.
-  **Checkpoint** — um ponto de parada para o professor validar o progresso do grupo antes de seguir adiante.

 **Objetivo da atividade**

Capacitar os alunos a elicitar, modelar e alinhar requisitos de negócio com decisões de design analítico e pipelines de dados utilizando o GR4ML, garantindo que o modelo de Machine Learning atenda a um valor real de negócio — e não apenas a uma métrica técnica isolada.

Cronograma sugerido

Fase	Duração	Conteúdo
Fase 0 — Alinhamento	20 min	Escopo do projeto, stakeholder principal e dor de negócio
Fase 1 — Business View	45 min	Atores, objetivos, indicadores, decisões e perguntas de negócio
Fase 2 — Analytics Design View	45 min	Tipo de análise, tarefas de ML, algoritmos, softgoals e métricas
Fase 3 — Data Preparation View	45 min	Fontes de dados, transformações e pipeline até o dataset final
Fase 4 — Dos modelos aos requisitos	30 min	Tradução dos modelos em Requisitos Funcionais, Não-Funcionais e de Dados

As três visões do GR4ML, em uma tabela

Visão	Pergunta que responde	Quem pensaria assim, na vida real	O que sai dela
1. Business View	Quem precisa de quê, e por quê?	Gestor / dono do produto	Diagrama Ator → Goal → Decision Goal → Question Goals
2. Analytics Design View	Que modelo resolve isso, com qual qualidade?	Cientista de dados	Tarefas de ML, algoritmos e métricas ligadas aos softgoals
3. Data Preparation View	De onde vêm os dados e como chegam prontos?	Engenheiro de dados	Pipeline de dados brutos até features prontas



FASE 0 — Alinhamento de Contexto

20 minutos · antes de abrir qualquer ferramenta de modelagem

Ideia central: antes de pensar em modelo ou algoritmo, o grupo precisa conseguir resumir o projeto em um parágrafo simples. Identifiquem claramente quem é o principal patrocinador (stakeholder) do projeto e qual dor de negócio motivou a criação do sistema de ML.



Exemplo (streaming)

- "O Gerente de Retenção de Clientes da plataforma quer reduzir o cancelamento de assinaturas, que hoje é decidido caso a caso sem nenhum critério preditivo, causando perda de receita recorrente."



ENTREGÁVEL DESTE PASSO: Um parágrafo curto (3–5 linhas) descrevendo o stakeholder principal e a dor de negócio do projeto de vocês. Essa frase será a 'âncora' de todas as fases seguintes.



Espaço para o grupo preencher

*"O Auditor do órgão de controladoria quer aumentar a tempestividade na identificação de irregularidades nas licitações públicas, considerando que hoje, existe um volume enorme de licitações e uma equipe de trabalho limitada, criando um ambiente em que a **priorização de análise** é um fator decisivo para que ações sejam tomadas em tempo hábil".*



FASE 1 — Business View (Visão de Negócio)

45 minutos · mapeando intenções estratégicas, sem pensar em algoritmos ainda

Objetivo desta fase: mapear as intenções estratégicas do negócio e como o ML pode apoiar a tomada de decisão humana.

PASSO 1.1 Identificar o Ator de negócio

Pergunte: quem vai usar essa solução no dia a dia? Essa pessoa representa qual papel na organização?



Exemplos de Atores

- Streaming → Gerente de Retenção de Clientes
- Fraude → Gerente de Prevenção a Fraudes
- Saúde → Médico Oncologista
- Hospital (fluxo de atendimento) → Coordenador de Enfermagem



ENTREGÁVEL DESTE PASSO: Uma tabela com 1 linha por ator, contendo nome do ator e papel na organização (2 a 4 atores costuma bastar).



Espaço para o grupo preencher

Nome do Ator	Papel na organização
Auditor responsável pela análise de licitações	Analisar e identificar irregularidades em licitações públicas

PASSO 1.2 Definir o Goal (objetivo) e anotar expectativas de qualidade

Goal: o que esse ator quer alcançar, de forma mensurável. Indicador: a métrica numérica que mostra progresso desse Goal. Além disso, anotem (ainda de forma informal) frases do stakeholder sobre o que ele valoriza além do número principal — isso será formalizado como Softgoal só na Fase 2.

Exemplo (streaming)

- Goal: "Reduzir o cancelamento de assinaturas em 15% este ano"
- Indicador: taxa mensal de churn (%) — atual: 5% · meta: 4,25%
- Anotação informal de qualidade: "O time de retenção mencionou que a lista de clientes em risco precisa estar pronta toda segunda-feira de manhã, sem exceção."

 **ENTREGÁVEL DESTE PASSO:** Para cada ator: o Goal, o Indicador (com valor atual e meta, se souberem) e 2–3 frases de qualidade esperada, em linguagem do negócio (ainda sem termos técnicos).

Espaço para o grupo preencher

Ator	Goal (objetivo) (dor)	Indicador (métrica)	Expectativas de qualidade (informal)
Auditor responsável pela análise de licitações	Reduzir o tempo de triagem de irregularidades no edital	Dias entre publicação do edital e geração do alerta	"A priorização precisa ser confiável." "O modelo precisa acertar a maioria dos casos."
Auditor responsável pela análise de licitações	Reduzir o tempo de triagem de irregularidades no candidato	Dias entre encerramento de inscrições e geração do alerta	"Preciso da explicação de por que foi sinalizado." "Não posso ter muitos falsos alarmes."

PASSO 1.3 Decision Goal — a decisão que o ator precisa tomar

Uma decisão é sempre uma escolha entre opções — algo que alguém faz repetidamente. Se vocês não conseguem descrever uma escolha concreta, ainda não acharam a decisão certa.

Exemplos

- Streaming: "Decidir para quais clientes oferecer um desconto de retenção este mês" (opções: desconto A, desconto B, nenhuma ação)
- Fraude: "Decidir se uma transação deve ser bloqueada, sinalizada para revisão manual, ou aprovada"
- Hospital: "Decidir qual paciente deve ser atendido primeiro na triagem"

Cuidado com este erro comum

"Entender os clientes" não é uma decisão — é um desejo vago. Pergunte sempre: decidir entre o quê?

 **ENTREGÁVEL DESTE PASSO:** Uma frase por ator, no formato: '[Ator] precisa decidir [entre quais opções], com que frequência'.



Espaço para o grupo preencher

*“O Auditor responsável pela análise de licitações, precisa decidir entre **priorizar para aprofundamento, colocar em fila ou descartar uma investigação a cada edital publicado**”*

*“O Auditor responsável pela análise de licitações, precisa decidir entre **monitorar este candidato, ou não monitorar a cada inscrição encerrada**”.*

PASSO 1.4 Question Goals — as perguntas que respondem à decisão

Desdobrem o Decision Goal em uma ou mais perguntas específicas que o modelo de ML precisa responder para apoiar a decisão. Especifiquem também o tipo de pergunta (quem/o quê/quando...), o tempo verbal (passado/presente/futuro) e a frequência necessária da resposta.



Exemplos

- *Streaming*: "Quais clientes têm alta chance de cancelar a assinatura nos próximos 30 dias?" → tipo: quem · tempo: futuro · frequência: mensal
- *Fraude*: "Essa transação específica é fraudulenta?" → tipo: o quê · tempo: presente · frequência: tempo real
- *Hospital*: "Qual paciente tem maior risco de piora nas próximas 2 horas?" → tipo: quem · tempo: futuro · frequência: tempo real




ENTREGÁVEL DESTE PASSO: Para cada Decision Goal, uma ou mais Question Goals, indicando tipo, tempo verbal e frequência.

Question Goal (a pergunta)	Tipo	Tempo (passado/presente/futuro)	Frequência
Qual é o score de anomalia de cada edital?	O quê	Presente	A cada edital publicado
Quais atributos do edital são anômalos?	O quê	Presente	A cada edital publicado
O desvio é significativo o suficiente para justificar investigação?	O quê	Presente	A cada edital publicado
Qual é o score de risco de cada candidato?	O quê	Presente	A cada inscrição encerrada
Qual candidato tem histórico anterior de problemas?	Quem	Presente	A cada inscrição encerrada
As características suspeitas são padrão de fraude conhecida?	O quê	Presente	A cada inscrição encerrada

Entregável final da Fase 1

Desenhem (à mão, em slide, ou em ferramenta de diagramação) um diagrama conectando: Ator → Goal → Decision Goal → Question Goal(s), com os indicadores e as anotações informais de qualidade ao lado do Goal.



CHECKPOINT

Antes de seguir para a Fase 2, mostrem esse diagrama ao professor. Nenhum grupo deve avançar sem ter clareza total sobre o problema de negócio.

2 FASE 2 — Analytics Design View

45 minutos · traduzindo a pergunta de negócio em especificação técnica

Objetivo desta fase: traduzir as perguntas de negócio da Fase 1 em especificações técnicas de Machine Learning — e é aqui que formalizamos os Softgoals.

PASSO 2.1 Tipo de análise

Para cada Question Goal da Fase 1, classifiquem o tipo de análise necessária.

Tipo	O que faz	Exemplo
Preditiva	Prever um valor futuro ou desconhecido	Prever se o cliente vai cancelar
Descritiva	Resumir/explicar o conjunto de dados	Agrupar clientes em perfis de comportamento
Prescritiva	Recomendar a melhor ação entre opções	Recomendar qual desconto oferecer a cada cliente

 **ENTREGÁVEL DESTE PASSO:** Classificação (Preditiva/Descritiva/Prescritiva) para cada Question Goal, com uma frase justificando.

Question Goal	Tipo de análise	Justificativa
Qual é o score de anomalia de cada edital?	Descritiva	Analisa editais já publicados buscando anomalias presentes. Não tenta prever futuros editais anômalos, apenas descreve o desvio nos dados que já existem.
Quais atributos do edital são anômalos?	Descritiva	Examina características já registradas no edital para explicar qual aspecto causa a anomalia. Não prevê — apenas descreve o padrão observado.
O desvio é significativo o suficiente para justificar investigação?	Descritiva	Avalia a magnitude da anomalia atual contra limiares históricos. Não prediz futuro — classifica a relevância do desvio presente nos dados.
Qual é o score de risco de cada candidato?	Descritiva	Avalia candidatos já inscritos baseado em histórico e cadastro existentes. Não prediz se candidatos futuros serão problemáticos, apenas descreve risco do inscrito hoje.
Qual candidato tem histórico anterior de problemas?	Descritiva	Consulta registros históricos já existentes em CEIS/CNEP. Não prevê, apenas expõe dados documentados.
As características suspeitas são padrão de fraude conhecida?	Descritiva	Compara anomalias detectadas agora contra padrões de fraude já conhecidos e documentados . Não prediz — classifica o padrão observado.

PASSO 2.2 Tarefa de ML e algoritmos candidatos

Desçam um nível de abstração: que tarefa técnica de ML corresponde a essa análise, e quais algoritmos poderiam resolvê-la? Listem do mais simples ao mais sofisticado — ainda não é hora de escolher 'o melhor'.

Exemplo (streaming — "prever cancelamento")

- *Tarefa de ML: Classificação Binária (vai cancelar / não vai cancelar)*
- *Algoritmos candidatos: regra manual (ex.: 'sem login há 20+ dias'), Regressão Logística, Random Forest, XGBoost, Rede Neural*

Se a tarefa parecer grande demais, quebrem em sub-tarefas (ex.: 'cancelamento voluntário' vs. 'cancelamento por falha de pagamento' — causas e dados diferentes).

 **ENTREGÁVEL DESTE PASSO:** Para cada Meta Analítica: a tarefa de ML correspondente e uma lista de 2–4 algoritmos candidatos.

Meta Analítica	Tarefa de ML	Algoritmos candidatos
Detectar editais com características anômalas	Anomaly Detection	• Z-score/IQR • Isolation Forest • Autoencoder
Identificar quais atributos causam a anomalia	Feature Importance / Explicabilidade	• SHAP • Permutation Importance • Tree-based Feature Selection
Classificar se a anomalia justifica investigação	Threshold Classification	• Decision Tree • Logistic Regression • Regra Manual
Quantificar risco de candidatos inscritos	Anomaly Detection / Risk Scoring	• Z-score/IQR • Isolation Forest • Autoencoder
Recuperar histórico de candidato em CEIS/CNEP	Data Lookup / Record Matching	• SQL Query • Fuzzy Matching (string similarity) • Exact Match
Classificar tipo de anomalia detectada (padrão conhecido)	Pattern Classification / Rule-based	Regras baseadas em padrões conhecidos (fraude à licitação, conluio, etc)

PASSO 2.3 Formalizar os Softgoals

Transformem as anotações informais de qualidade da Fase 1 (Passo 1.2) em Softgoals formais — requisitos de qualidade que vão pesar na escolha do algoritmo.

Exemplos, com a origem no negócio

- *"Não quero muitos alarmes falsos" (fraude) → Softgoal: Baixa taxa de Falso Positivo / Alta Precisão*
- *"Preciso entender o motivo da recomendação" (saúde) → Softgoal: Explicabilidade*

- "A lista precisa estar pronta toda segunda de manhã" (streaming) → Softgoal: Baixa latência / lote compatível com o prazo
- Softgoals técnicos que o time de dados pode trazer, mesmo sem o stakeholder ter pedido: Custo de treino/operação, Privacidade dos dados, Robustez a mudanças de comportamento (drift)

📌 **ENTREGÁVEL DESTE PASSO:** Lista de 3–5 Softgoals formais, cada um citando de qual anotação da Fase 1 ele se origina (ou indicando que é um softgoal técnico adicional).

Softgoal	Origem (frase do stakeholder ou 'técnico')
Alta Confiabilidade	"A priorização precisa ser confiável"
Alta Acurácia / Taxa de Acerto	"O modelo precisa acertar a maioria dos casos"
Explicabilidade	"Preciso da explicação de por que foi sinalizado"
Baixa Taxa de Falso Positivo (Alta Precisão)	"Não posso ter muitos falsos alarmes"

PASSO 2.4 Vincular Softgoals a métricas de ML tangíveis

🌟 O "pulo do gato" do GR4ML

Todo Softgoal precisa virar uma métrica técnica mensurável, ou ele fica bonito no papel e não influencia nada na prática. Alunos de computação tendem a otimizar só a Acurácia — mas se o negócio exige Explicabilidade, um modelo caixa-preta sem SHAP/LIME viola um requisito de negócio, mesmo acertando mais.

💡 Exemplos de vínculo Softgoal → Métrica

- Fraude: "Evitar perturbar clientes inocentes" → alta Precisão / baixa taxa de Falso Positivo
- Saúde: "Explicabilidade" → uso obrigatório de SHAP/LIME, ou restrição a modelos interpretáveis
- Streaming: "Compatível com o prazo semanal" → tempo de inferência em lote < 2h para toda a base

📌 **ENTREGÁVEL DESTE PASSO:** Uma tabela cruzando Algoritmos (Passo 2.2) × Softgoals (Passo 2.3), com a métrica usada em cada cruzamento, e uma conclusão de qual algoritmo o grupo escolheria.

Algoritmo	Softgoal 1: Alta Confiabilidade (Métrica)	Softgoal 2: Alta Acurácia (Métrica)	Softgoal 3: Explicabilidade (Métrica)	Softgoal 4: Baixa Taxa Falso Positivo (Métrica)
Z-score/IQR	Regras simples e transparentes	Detecção univariada limitada	Fórmula estatística explícita	Muitos falsos alarmes (threshold difícil de calibrar)
Isolation Forest	Padrões multidimensionais robustos	Detecção multidimensional boa	SHAP integrado (explica cada atributo)	Threshold ajustável (precision controlável)
Autoencoder	Padrões complexos capturados	Detecção muito sensível	Caixa-preta (sem SHAP/LIME)	Difícil de controlar (não interpretável)

Conclusão do grupo — qual algoritmo escolheriam e por quê:

Avaliamos três algoritmos candidatos para Anomaly Detection (Isolation Forest, Z-score/IQR e Autoencoder) contra os quatro Softgoals do projeto.

- **Z-score/IQR** é simples e transparente, mas trabalha em apenas uma dimensão por vez. Em um cenário de detecção de fraudes em licitações, onde anomalias envolvem combinações complexas (valor + região + fornecedor + padrão temporal), essa abordagem univariada não atende adequadamente ao Softgoal 1 (Alta Confiabilidade).
- **Autoencoder**, embora capture padrões muito complexos, é uma rede neural caixa-preta. Não conseguimos explicar ao auditor *por quê* um edital específico foi sinalizado. Isso viola diretamente o Softgoal 3 (Explicabilidade), que é não-negociável em um contexto de auditoria pública onde decisões precisam ser justificáveis e rastreáveis.

Isolation Forest é a escolha que equilibra todos os requisitos:

- Trabalha com múltiplas dimensões simultaneamente (Softgoal 1: Alta Confiabilidade)
- Detecta anomalias em dados não-rotulados, adequado para nosso contexto (Softgoal 2: Alta Acurácia)
- Integra-se perfeitamente com SHAP para fornecer explicações por atributo — o auditor vê exatamente quais características dispararam o alerta (Softgoal 3: Explicabilidade)
- Permite ajuste fino do threshold de contaminação, permitindo uma abordagem conservadora que minimiza falsos alarmes (Softgoal 4: Baixa Taxa de Falso Positivo)

Por essas razões, **Isolation Forest é o algoritmo escolhido** como modelo principal de detecção de anomalias para editais e candidatos.

PASSO 2.5 Conectar de volta ao indicador de negócio

Fechem o ciclo com a Fase 1: expliquem como a melhoria esperada no modelo se traduz em melhoria no indicador de negócio.



Exemplo (streaming)

- "Se o modelo identificar corretamente 80% dos clientes que vão cancelar, e a campanha de retenção converter 30% deles, esperamos reduzir o churn mensal de 5% para ~4,2%."



ENTREGÁVEL DESTE PASSO: Um parágrafo curto conectando o desempenho esperado do modelo ao Indicador definido no Passo 1.2.



Espaço para o grupo preencher

O Isolation Forest com SHAP melhora a **eficiência da análise dentro do ciclo mensal**. Quando os dados da licitações do mês N são liberados (final/início do mês), o modelo:

1. **Processa todos os editais/candidatos em lote:** Reduz o tempo de análise de semanas (se feita manualmente) para horas.
2. **Prioriza automaticamente:** Dos 1000+ editais mensais, identifica apenas os anômalos (talvez 50-100). O auditor não revisa 1000 — revisa 50.
3. **SHAP acelera cada análise:** Ao invés de investigar cada suspeito do zero, o auditor recebe explicações estruturadas sobre os atributos suspeitos, reduzindo tempo de investigação por caso.

Resultado no indicador: O tempo desde a liberação mensal dos dados até a conclusão da triagem de anomalias **reduz significativamente**, permitindo que ações corretivas sejam tomadas ainda durante o mês seguinte, em vez de meses depois.

CHECKPOINT

Antes de seguir para a Fase 3, garantam que cada Softgoal tem uma métrica associada — não deixem nenhum 'bonito no papel'.

3 FASE 3 — Data Preparation View

45 minutos · conectando os algoritmos às fontes de dados reais

Objetivo desta fase: conectar os algoritmos escolhidos às fontes de dados reais necessárias para treiná-los e alimentá-los.

PASSO 3.1 Fontes de dados (entidades e atributos)

Identifiquem as entidades e atributos do mundo real necessários para o modelo — mesmo que hipotéticos.

💡 Exemplo (streaming)

- *Cadastro do Cliente: nome, idade, cidade, data de assinatura*
- *Histórico de Visualização: o quê assistiu, quando, por quanto tempo*
- *Atendimentos ao Suporte: data, motivo, se foi resolvido*
- *Logs de Pagamento: forma de pagamento, se houve falha de cobrança*

📌 **ENTREGÁVEL DESTE PASSO:** Lista das tabelas/fontes de dados brutos, com 3–5 campos principais de cada uma.

Fonte de dados (tabela)	Principais campos/atributos
Licitação (YYYYMM_Licitação.csv)	ID da licitação, órgão, modalidade, valor estimado, valor homologado, data de abertura, data de encerramento

PASSO 3.2 Data Operations — transformações

Descrevam as transformações necessárias para os dados brutos virarem features (colunas prontas para o modelo).

💡 Tipos de tratamento, com exemplos

- *Tratamento de nulos: preencher ou descartar registros incompletos*
- *Normalização: colocar variáveis em escalas comparáveis*
- *One-Hot Encoding: transformar categorias (ex.: forma de pagamento) em colunas binárias*
- *Agregações temporais: calcular 'horas assistidas por semana' a partir de logs brutos*
- *Integração: juntar tabelas usando o ID do cliente como chave*

📌 **ENTREGÁVEL DESTE PASSO:** Lista numerada das transformações aplicadas, na ordem em que ocorrem, do dado bruto até a tabela final.

Nº	Transformação aplicada	Tabela(s) de origem
1	Tratamento de nulos	Licitações
2	Normalização	Licitações

Nº	Transformação aplicada	Tabela(s) de origem
3	Agregações temporais	Licitações
4	One-Hot Encoding	Licitações

PASSO 3.3 Dataset final e Pipeline


Mostrem a 'tabela final' que o modelo realmente usa — uma linha por unidade de análise, uma coluna por feature — e conectem-na diretamente às tarefas de ML da Fase 2.

Exemplo de dataset preparado (streaming)

• Colunas: *Cliente_ID* | *Dias sem logar* | *Horas assistidas/semana* | *Nº reclamações (3 meses)* | *Já teve falha de pagamento?* | *Cancelou (rótulo)*

 **ENTREGÁVEL DESTE PASSO:** Exemplo de tabela final (pode ser fictício, poucas linhas) + um diagrama simples de pipeline: Fontes brutas → Transformações → Dataset Final → Algoritmo.

Coluna (feature)	Descrição	De qual fonte / transformação vem
Tempo decorrido	Tempo em dias decorrido entre a abertura da licitação e o fechamento da mesma.	(YYYYMM_Licitação.csv) data_inicial e data_final
Valor da licitação	Valor proposto da licitação	(YYYYMM_Licitação.csv)
Modalidade de compra	Pregão, Pregão-RP, Dispensa, Inexigibilidade, Concorrência, Tomada de Preços, Convite	(YYYYMM_Licitação.csv)
Data do resultado da compra	Data em que a compra foi fechada	(YYYYMM_Licitação.csv)



CHECKPOINT

Um colega de fora do grupo, lendo o pipeline, deveria entender de onde vem cada coluna da tabela final.

Ferramentas recomendadas

Como o GR4ML estende conceitos do i* (iStar), os alunos podem utilizar:

- **Ferramentas de diagramação geral:** Miro, Lucidchart ou Draw.io, criando uma legenda própria para os elementos do GR4ML:
 - Retângulos arredondados → Goals (Strategic Goal, Decision Goal, Question Goal)
 - Nuvens → Softgoals
 - Hexágonos → Tasks/Algoritmos
- **Ferramentas acadêmicas baseadas em i*:** para quem preferir mais formalismo, a piStar tool, adaptada com estereótipos do GR4ML, ajuda na modelagem orientada a objetivos.

Verificação final

Antes de entregar, completem esta frase única, sem inventar nada que não esteja documentado nas fases anteriores. Se alguma parte não existir no material do grupo, é sinal de que uma fase ficou incompleta — voltem e revisem.

Frase de verificação

"Para ajudar [Ator] a decidir [Decision Goal], respondendo à pergunta [Question Goal], vamos usar [Algoritmo], que satisfaz os softgoals [Softgoals] medidos por [Métricas], usando os dados [Dataset Preparado] vindos de [Fontes de Dados]. Isso deve impactar o indicador [Indicador] em [magnitude esperada]."

Preencham a frase com o projeto de vocês

Para ajudar o auditor a reduzir o tempo de esforço para encontrar fraudes, respondendo à pergunta *'Quais licitações do período fogem do padrão?'*, vamos usar o algoritmo **Isolation Forest**, que satisfaz os **softgoals de baixa taxa de falso positivo, explicabilidade e privacidade dos dados, medidos pelo tempo médio levado para encontrar fraudes, pelo aumento do valor auditado, pelo número de fraudes confirmadas** e pela quantidade de provas fornecidas, usando os dados do Dataset_Preparado_Editais vindos da tabela Licitação (YYYYMM_Licitação.csv) da CGU. Isso deve impactar a tempestividade na reversão de danos em tempo hábil.

FASE 4 — Dos Modelos aos Requisitos

30 minutos · transformando os diagramas GR4ML em uma lista de requisitos formal

Até aqui, o grupo construiu três diagramas/modelos. Mas um diagrama, sozinho, ainda não é um documento de requisitos — é preciso 'traduzir' cada elemento do modelo em frases claras, testáveis, que um time de engenharia consiga implementar e verificar. Essa tradução segue sempre o mesmo caminho: cada elemento do GR4ML já modelado nas fases anteriores dá origem a um tipo específico de requisito.

Por que isso importa

Um Decision Goal ou um Softgoal, por si só, é uma intenção — não uma instrução que um desenvolvedor consiga implementar ou testar. A elicitação só termina de fato quando a intenção vira um requisito redigido de forma objetiva, rastreável até o elemento do modelo que o originou.

Mapa de tradução: do elemento do GR4ML ao tipo de requisito

Elemento já modelado	Tipo de requisito gerado	Pergunta-guia para redigir
Decision Goal + Question Goal + Insight (Fase 1)	Requisito Funcional (RF)	O que o sistema de IA deve calcular, inferir ou exibir para que o Ator consiga tomar a decisão necessária?
Softgoal + Métrica de ML (Fase 2)	Requisito Não-Funcional (RNF)	Como o sistema deve se comportar em termos de qualidade (explicabilidade, precisão, segurança) e qual a meta mínima estipulada?
Entity + Transformações (Pipeline) (Fase 3)	Requisito de Dados (RD)	Quais tabelas e atributos brutos precisam passar por limpezas, engenharias de atributos ou escalas para alimentar os Requisitos Funcionais?
Indicador de Negócio (KPI) (Fase 1)	Critério de Aceitação	Qual é o impacto quantitativo que a implantação do software deve gerar no indicador estratégico do negócio?

PASSO 4.1 Redigir os Requisitos Funcionais (RF)

Um Requisito Funcional descreve uma capacidade que o sistema deve ter. Ele nasce da junção entre a decisão (Decision Goal), a pergunta que a apoia (Question Goal) e o insight que a responde (Fase 1).



Modelo de frase (template)

- "O sistema deve [ação/cálculo], a partir de [dados de entrada], para permitir que [Ator] [decisão apoiada]."



Exemplo preenchido (streaming)

- "O sistema deve calcular uma pontuação de risco de cancelamento (0 a 100) para cada cliente ativo, a partir do histórico de uso, suporte e pagamento dos últimos 12 meses, atualizada semanalmente, para permitir que o Gerente de Retenção decida quais clientes recebem desconto."



ENTREGÁVEL DESTE PASSO: Um Requisito Funcional (RF) redigido para cada Insight identificado na Fase 1, seguindo o template acima.

ID	Requisito Funcional (RF)	Origem no modelo (Insight/Decision Goal)
RF-01	O sistema deve calcular um score de anomalia para cada edital de licitação publicado, a partir do valor estimado tratado, do tempo decorrido calculado e das modalidades de compra vetorizadas (todas na escala normalizada de 0 a 1), para permitir que o Auditor decida se prioriza para aprofundamento, coloca em fila ou descarta uma investigação	Decision Goal 1: Decidir priorização de investigação do edital + Question Goal: "Qual é o score de anomalia de cada edital?"
RF-02	O sistema deve gerar e exibir a atribuição local de impacto (valores explicativos SHAP) por atributo de cada edital suspeito sinalizado, a partir da execução interna do modelo de Machine Learning, para permitir que o Auditor analise quais aspectos causaram o desvio e fundamente a justificativa técnica de abertura da investigação	Question Goal: "Quais atributos do edital são anômalos?" + Softgoal: Explicabilidade ("Preciso da explicação de por que foi sinalizado")
RF-03	O sistema deve classificar a significância do desvio do edital (categorizando-o como alta prioridade, média prioridade ou descarte), a partir da comparação do score gerado contra limiares (thresholds) de contaminação pré-definidos e ajustáveis pelo usuário, para permitir que o Auditor otimize o esforço de triagem concentrando-se apenas nos casos de maior relevância material.	Question Goal: "O desvio é significativo o suficiente para justificar investigação?"
RF-04	O sistema deve calcular um score de risco para cada fornecedor concorrente em uma licitação encerrada, a partir do mapeamento de vínculos cadastrais e cruzamento de CPF/CNPJ, para permitir que o Auditor decida se monitora ou não monitora o candidato	Decision Goal 2: Decidir monitoramento de candidatos + Question Goal: "Qual é o score de risco de cada candidato?"
RF-05	O sistema deve identificar se um fornecedor possui sanções ativas, a partir do cruzamento por casamento exato (<i>Exact Match</i>) de documentos contra as bases históricas do CEIS e do CNEP, para permitir que o Auditor identifique proponentes inidôneos impedidos de licitar e emita alertas de conformidade	Question Goal: "Qual candidato tem histórico anterior de problemas?"
RF-06	O sistema deve comparar os padrões de desvio detectados nos editais e candidatos contra tipologias de fraudes conhecidas, a partir de regras analíticas pré-mapeadas (como indícios de conluio ou direcionamento de escopo), para permitir que o Auditor classifique a natureza da suspeita antes de iniciar a apuração em campo	Question Goal: "As características suspeitas são padrão de fraude conhecida?"

PASSO 4.2 Redigir os Requisitos Não-Funcionais (RNF)

Um Requisito Não-Funcional descreve uma qualidade que o sistema deve garantir — nasce diretamente dos Softgoals formalizados e das métricas que vocês vincularam a eles no Passo 2.4.

💡 Modelo de frase (template)

- "O sistema deve garantir [qualidade/softgoal], medida por [métrica], com [meta/limite]."

💡 Exemplos preenchidos

- "O sistema deve fornecer explicabilidade para cada predição de risco, medida pela disponibilidade de valores SHAP por cliente." (origem: Softgoal Explicabilidade)
- "O sistema deve processar toda a base de clientes em lote em menos de 2 horas." (origem: Softgoal Baixa latência / prazo semanal)

🔗 **ENTREGÁVEL DESTE PASSO:** Um Requisito Não-Funcional (RNF) redigido para cada Softgoal formalizado no Passo 2.3, usando a métrica definida no Passo 2.4.

ID	Requisito Não-Funcional (RNF)	Origem no modelo (Softgoal/Métrica)
RNF-01	O sistema deve garantir baixa taxa de falso positivo, medida pelo número de fraudes de fato confirmadas após a triagem em relação ao total de alertas emitidos pelo Isolation Forest, com meta de que a grande maioria dos editais sinalizados como de alta prioridade seja validada como irregular	Softgoal: Baixa Taxa de Falso Positivo Métrica: Fraudes confirmadas
RNF-02	O sistema deve garantir explicabilidade, medida pelo número de provas fornecidas e justificativas de desvios para cada edital suspeito, com meta de exibir na tela de triagem quais atributos específicos dispararam o alerta para embasar a decisão do auditor	Softgoal: Explicabilidade Métrica: Número de provas fornecidas
RNF-03	O sistema deve garantir alta confiabilidade, medida pelo aumento do valor monetário total auditado sob suspeita de desvios, com meta de priorizar e direcionar o esforço de investigação para os certames de maior relevância material e financeira	Softgoal: Alta Confiabilidade Métrica: Aumentar o valor auditado
RNF-04	O sistema deve garantir alta eficiência na redução do tempo de esforço, medida pelo tempo médio levado para encontrar e triar fraudes em cada ciclo mensal, com meta de processar todo o lote e gerar os alertas em menos de 48 horas após a liberação dos dados pela CGU	Softgoal: Redução do esforço / Tempestividade Métrica: Tempo médio levado para encontrar fraudes
RNF-05	O sistema deve garantir a privacidade dos dados, medida pela rastreabilidade e controle de acesso aos CPFs/CNPJs de fornecedores, com meta de conformidade total com as regras da LGPD e garantia de que dados sensíveis de licitantes não fiquem expostos publicamente	Softgoal: Privacidade dos dados Métrica: Controle de acesso e integridade cadastral

PASSO 4.3 Redigir os Requisitos de Dados (RD)

Um Requisito de Dados descreve o que precisa ser coletado, integrado ou tratado — nasce das Entidades, do Dataset Preparado e das transformações mapeadas na Fase 3.

💡 Modelo de frase (template)

- "O sistema deve integrar/coletar/tratar [dado], proveniente de [fonte], aplicando [transformação], para alimentar [RF correspondente]."

💡 Exemplo preenchido (streaming)

- "O sistema deve integrar dados de Cadastro do Cliente, Histórico de Visualização, Atendimentos ao Suporte e Pagamentos, tratando valores nulos e agregando o histórico de visualização em 'horas assistidas por semana', para alimentar o requisito RF-01."

🔗 **ENTREGÁVEL DESTE PASSO:** Um ou mais Requisitos de Dados (RD), cobrindo as fontes e transformações da Fase 3, cada um referenciando o RF que ele alimenta.

ID	Requisito de Dados (RD)	RF que este dado alimenta
RD-01	O sistema deve coletar e ler o lote de dados brutos das licitações, proveniente do arquivo mensal YYYYMM_Licitação.csv da CGU, contendo campos como identificadores, valores, datas e modalidades de compra, para alimentar o pipeline geral de análise	RF-01 (Cálculo do score de anomalias)
RD-02	O sistema deve tratar o atributo contínuo valor estimado, proveniente do arquivo YYYYMM_Licitação.csv, aplicando o operador Tratamento de Nulos (substituição de campos vazios pela mediana histórica do órgão emissor ou por 0.0), para alimentar a etapa subsequente de escalonamento	RF-01 (Cálculo do score de anomalias)
RD-03	O sistema deve tratar os atributos textuais data de abertura e data de encerramento, provenientes do arquivo YYYYMM_Licitação.csv, aplicando o operador Cálculo de Diferença Temporal (subtração em dias) para criar a nova feature tempo decorrido, para alimentar a etapa subsequente de escalonamento	RF-01 (Cálculo do score de anomalias)
RD-04	O sistema deve tratar o atributo categórico modalidade, proveniente do arquivo YYYYMM_Licitação.csv, aplicando o operador One-Hot Encoding para gerar as variáveis binárias Mod_pregao e Mod_Dispenza, gravando-as diretamente no dataset de destino	RF-01 (Cálculo do score de anomalias)
RD-05	O sistema deve normalizar os atributos contínuos valor estimado (já tratado) e tempo decorrido (já calculado), provenientes das etapas anteriores, aplicando o operador Normalização Min-Max para esmagar os valores para a escala estrita de, gravando o resultado no dataset de destino	RF-01 (Cálculo do score de anomalias)

PASSO 4.4 Definir o Critério de Aceitação (fechando o ciclo com o negócio)

Por fim, reconectem tudo ao Indicador de negócio definido lá no Passo 1.2 — é isso que prova que os requisitos, uma vez implementados, geram valor real, e não apenas um modelo tecnicamente correto.

Modelo de frase (template)

- "Este conjunto de requisitos será considerado bem-sucedido se [indicador] atingir [meta], observado em [período/frequência]."

Exemplo preenchido (streaming)

- "Este conjunto de requisitos será considerado bem-sucedido se a taxa mensal de churn cair de 5% para 4,25% em até 6 meses após o lançamento."

 **ENTREGÁVEL DESTES PASSOS:** Uma frase de critério de aceitação, conectando os RF/RNF/RD ao Indicador de negócio da Fase 1.

"Este conjunto de requisitos será considerado bem-sucedido se o tempo de triagem de irregularidades no edital (dias entre a publicação do edital e a geração do alerta) cair de semanas (do processo manual) para horas, observado mensalmente a cada nova liberação de dados da CGU".

Como reconhecer um requisito bem escrito

Use sempre 'o sistema deve...' (nunca 'seria bom se' ou 'o ideal seria'). Um requisito por frase — não amarrem duas exigências na mesma sentença. Ele precisa ser testável: alguém de fora do grupo deveria conseguir dizer, olhando o sistema pronto, se aquele requisito foi ou não atendido. E ele precisa ser rastreável: sempre cite de qual elemento do modelo GR4ML (Decision Goal, Softgoal, Entidade) aquele requisito se originou — é essa rastreabilidade que prova que a elicitação foi feita de ponta a ponta, e não inventada na hora de escrever o documento.

CHECKPOINT

A tarefa só está completa quando existe uma lista numerada de RFs, RNFs e RDs, cada um rastreável a um elemento específico dos modelos das Fases 1 a 3, e um critério de aceitação ligado ao Indicador de negócio.



Estrutura do documento a ser entregue

- 1. Contexto do projeto (Fase 0)
- 2. Diagrama e tabelas da Business View (Fase 1)
- 3. Tabelas de tarefas/algoritmos/softgoals/métricas da Analytics Design View (Fase 2)
- 4. Diagrama de pipeline da Data Preparation View (Fase 3)
- 5. Frase de verificação final preenchida
- 6. Lista consolidada de Requisitos Funcionais, Não-Funcionais e de Dados, com critério de aceitação (Fase 4)
- 7. Reflexão crítica (½ página): o ML era realmente necessário aqui? O que a formalização dos Softgoals e a tradução para requisitos revelaram que não estava claro na conversa inicial com o stakeholder?

Reflexão crítica do grupo

1. O Machine Learning (ML) era realmente necessário aqui?

Sim. A triagem manual de milhares de editais mensais da CGU é inviável para uma equipe limitada de auditores. A programação tradicional baseada em regras estáticas (consultas SQL) não funciona porque os padrões de desvios mudam constantemente para burlar o sistema. O uso do algoritmo não-supervisionado Isolation Forest é necessário porque ele reduz o custo e o esforço de encontrar anomalias de forma multidimensional (cruzando valor, tempo e modalidade), sem depender de uma base de dados previamente rotulada com fraudes passadas.

2. O que a formalização dos Softgoals e a tradução para requisitos revelaram?

Revelaram que a qualidade do sistema de IA não se resume à acurácia do modelo matemático. Na conversa inicial, o auditor só pedia para "encontrar fraudes de forma rápida". Porém, a formalização dos Softgoals mostrou que:

- **Acurácia não é tudo:** Um modelo extremamente preciso, mas do tipo "caixa-preta", seria inútil para o órgão de controle, pois o auditor precisa de justificativas legais e rastreáveis para abrir uma investigação. Daí nasceu a necessidade obrigatória do requisito de Explicabilidade via SHAP (RF-02).
- **Falsos positivos inviabilizam o uso:** Excesso de alarmes falsos geraria fadiga no time e abandono do software. Isso exigiu que o sistema fornecesse um controle ajustável do limiar de contaminação do algoritmo (RF-03).